Wakacje 2020

Jakub Wiśniewski

Plan prezentacji

- Fairness
- fairmodels
- Blog
- Moduł fairness w dalex

Czym jest fairness - podsumowanie

- Część Responsible ML
- Zajmuje się oceną sprawiedliwości decyzji podejmowanych przez modele
- W perspektywie fairness model to 3 wektory:

Czy można jednoznacznie ocenić fairness? Na co uważać?

- Nie można, ale trzeba próbować!
- Zasada 4/5 (80%) w przypadku *statistical parity* [UNIFORM GUIDELINES• ON EMPLOYEE SELECTION PROCEDURES (1978)]
- Możliwe sprawdzanie nie tylko binarnych sensitive attributes ale także tych niebinarnych oraz ich przecięć

Gender Shades: Intersectional Accuracy Disparities in Commercial Gender Classification Joy Buolamwini , Timnit Gebru 2018

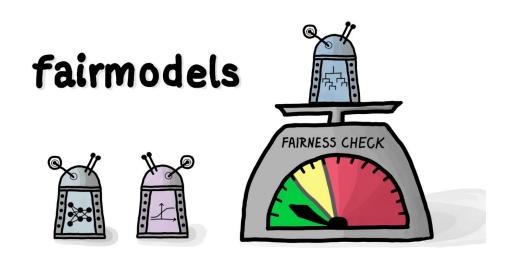
4.1. Key Findings on Evaluated Classifiers

- All classifiers perform better on male faces than female faces (8.1% - 20.6% difference in error rate)
- All classifiers perform better on lighter faces than darker faces (11.8% – 19.2% difference in error rate)
- All classifiers perform worst on darker female faces (20.8% - 34.7% error rate)
- Microsoft and IBM classifiers perform best on lighter male faces (error rates of 0.0% and 0.3% respectively)
- Face++ classifiers perform best on darker male faces (0.7% error rate)
- The maximum difference in error rate between the best and worst classified groups is 34.4%

fairmodels

- Jedyne* takie narzędzie w R
- Na CRAN od 20 sierpnia

- ☆ Star 34 CRAN 0.2.2 downloads 727/month
- Pojawia się w top 40 CRAN new packages (August)
- Wylistowane w "awesome-machine-learning-interpretability"

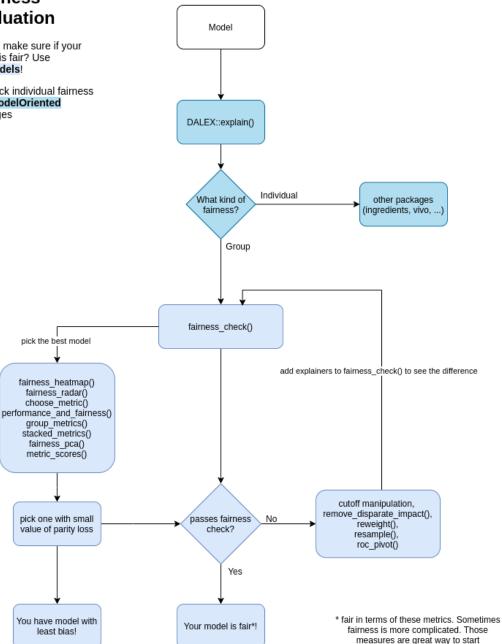


* które obsługuje modele oraz jest używalne

Fairness evaluation

How to make sure if your model is fair? Use fairmodels!

Or check individual fairness with ModelOriented packages



Jak używać fairmodels?



Metryki

- Metryki bazujące na macierzy pomyłek
- Pochodzące z nich metryki fairness
 - Equal opportunity (TPR)
 - Predictive parity (PPV)
 - Predictive equality (FPR)
 - Accuracy (ACC)
 - Statistical parity (STP = (TP+FP)/(TP+FP+TN+FN))

Parity loss – dlaczego zmiana?

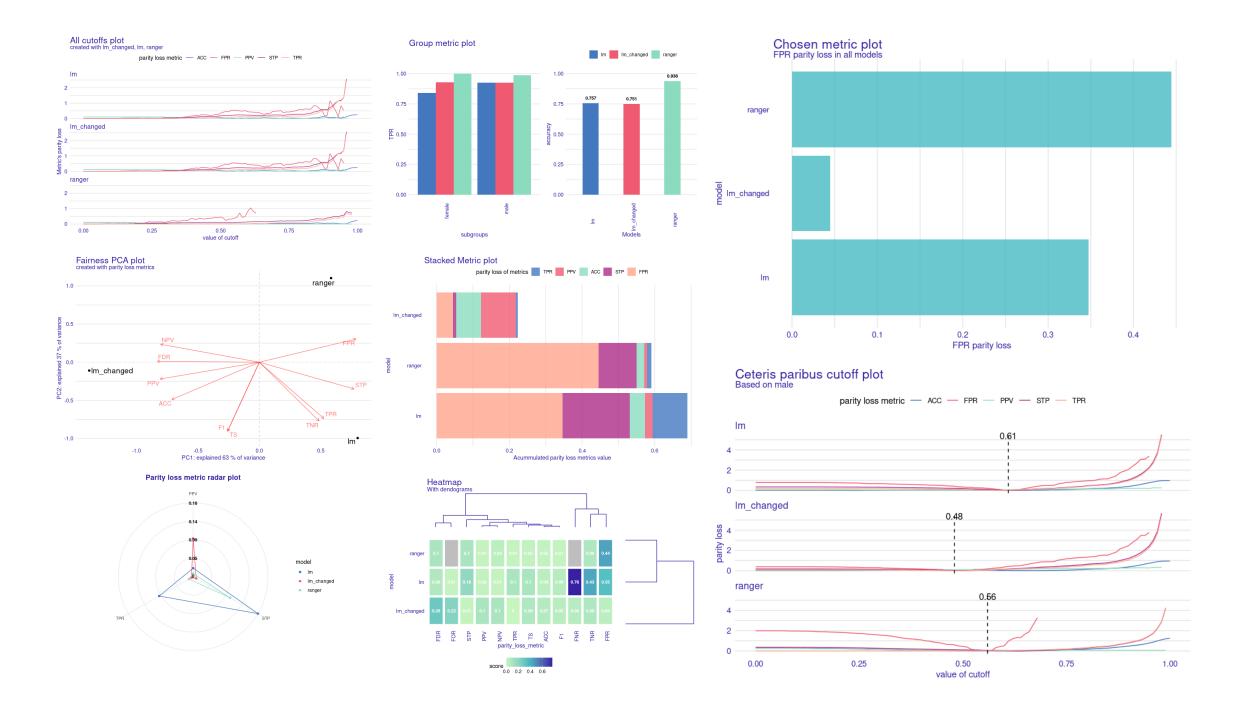
• Kiedyś:

• Teraz:

- Po co?
 - Aby dopasować się do Amerykańskiego prawa (four-fifths rule)
 - Aby dla dużych oraz małych wartości metryk interpretacja była ta sama.

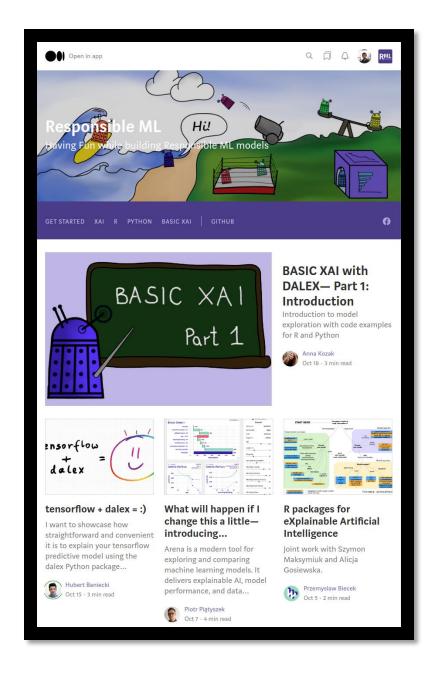
Wizualizacja fairness





Blog - miesięcznie

- 3027 wyświetleń
- Ponad 30 godzin spędzonych na czytaniu
- Średnio 63 unikalnych użytkowników dziennie
- Maksymalnie 294 użytkowników dziennie



Blog – statystyki

OCTOBER 2020

- Najwięcej zasięgów miały blogi Kasi oraz S&A&P
- Duży wpływ ma Linkedin Przemka: +230 wyświetleń

BASIC XAI with DALEX— Part 1: Introduction 3 min read · In ResponsibleML · View story · Details	176 +23K	115	65%	4	
tensorflow + dalex = :) 3 min read · In ResponsibleML · View story · Details	162	95	59%	6	
What will happen if I change this a little— i 4 min read · In ResponsibleML · View story · Details	245 +34K	108	44%	5	2 VAT
R packages for eXplainable Artificial Intellig 2 min read · In ResponsibleML · View story · Details	800 ÷28K	468	59%	10	RXAI
Imputing missing data in mlr3 with EMMA 4 min read · In ResponsibleML · View story · Details	261 +24K	137	52%	6	
SEPTEMBER 2020					
What is new in fairmodels? 4 min read · In ResponsibleML · View story · Details	231 +35K	115	50%	6	
What's new in DALEX and DALEXtra 7 min read · In ResponsibleML · View story · Details	435 +36K	155	36%	8	
Explaining models with Triplot, part 1 4 min read · In ResponsibleML · View story · Details	658 +41K	325	49%	8	~ TRIPLOT
How to use the Arena for exploration of ML 3 min read · In ResponsibleML · View story · Details	119	82	69%	7	
Introduction to ResponsibleML publication 3 min read · In ResponsibleML · View story · Details	151	87	58%	1	

VIEWS BY TRAFFIC SOURCE	800
Internal ③	0%
External referrals	100%
RSS readers (full text)	28K
linkedin.com	266
email, IM, and direct	182
r-bloggers.com	152
Android device (not Medium app)	65
google.com	16
feedly.com	16
news.google.com	6
<u>twitter.com</u>	5
mail.google.com	4
All other external referrals	12

Moduł do dalex (in progress)



LEPIEJ ZAIMPLEMENTOWANY FAIRMODELS



MNIEJ FUNKCJONALNOŚCI, SKUPIENIE SIĘ NA GŁÓWNYCH FEATURES



DOBRE PODSTAWY POD INDIVIDUAL FAIRNESS & FAIRNESS IN REGRESSION



ZAIMPLEMENTOWANY BAKCEND ORAZ 2 (MOIM ZDANIEM) NAJWAŻNIEJSZE WYKRESY

Interaktywne wykresy plotly



Koniec:)